

Bivariate Analysis

Analisis Bivariate — News Category Dataset

Materi Hari Rabu — Analisis Bivariate | Dataset: `final_clean_dataset.csv` (209.480 baris)


Tanggal: 5 Agustus 2026

Ringkasan

Laporan ini menganalisis hubungan antarvariabel (bivariate) pada dataset News Category, menggunakan scatter plot, grouped bar chart, line chart, cross tab (heatmap), boxplot per kategori, dan correlation heatmap. Total 6 visualisasi dan 10 insight dijabarkan di bawah ini.

Visualisasi & Analisis

1. Scatter Plot — Jumlah Kata Headline vs Short Description




Penjelasan: Scatter plot (sampel 3.000 baris + jitter) memetakan hubungan antara `Headline_Word_Count` dan `Short_Description_Word_Count`. Garis tren berwarna oranye menunjukkan arah hubungan linear antara keduanya.

Insight 1: Korelasi antara `Headline_Word_Count` dan `Short_Description_Word_Count` lemah dan negatif ($r = -0,23$) — headline yang lebih panjang justru sedikit berasosiasi dengan deskripsi yang lebih pendek, kemungkinan karena judul panjang sudah cukup menjelaskan isi berita.

Insight 2: Terlihat garis horizontal padat di $y = 3$ kata — ini adalah artefak dari proses cleaning sebelumnya, di mana 19.707 baris `Short_Description` kosong diisi placeholder 'Tidak ada deskripsi' (3 kata). Baris ini sebaiknya dikecualikan jika ingin menganalisis panjang deskripsi asli secara akurat.

2. Grouped Bar Chart — Top 5 Kategori x Tipe Penulis




Penjelasan: Grouped bar chart membandingkan jumlah artikel Single / Multiple / Unknown Author pada 5 kategori dengan artikel terbanyak.

Insight 1: *POLITICS* dan *ENTERTAINMENT* didominasi penulis tunggal (*Single*) — masing-masing 64% dan 75,6% artikelnya ditulis 1 orang, sesuai gaya jurnalisme opini/reportase individu.

Insight 2: *WELLNESS* dan *TRAVEL* justru didominasi penulis kolaboratif (*Multiple*) — 64,9% dan 72,4% — mengindikasikan artikel lifestyle/travel di *HuffPost* lebih sering ditulis tim atau melalui kontribusi editorial bersama.

3. Line Chart — Tren Jumlah Artikel per Tahun (Top 3 Kategori)




Penjelasan: Line chart menunjukkan tren volume artikel tahunan untuk 3 kategori terbesar: POLITICS, WELLNESS, dan ENTERTAINMENT.

Insight 1: Kategori WELLNESS anjlok drastis setelah 2014 (dari ± 2.700 ke hampir 0), bertepatan dengan munculnya kategori baru HEALTHY LIVING di tahun yang sama — pola ini menunjukkan kemungkinan besar perubahan taksonomi kategori di HuffPost (rename/split), bukan penurunan minat topik kesehatan secara nyata.

Insight 2: POLITICS memuncak tajam di 2016-2017 (>10.000 artikel/tahun, bertepatan dengan Pilpres AS 2016) sebelum ikut menurun drastis di 2018 seiring seluruh dataset — konsisten dengan temuan penurunan volume data keseluruhan pada laporan sebelumnya.

4. Cross Tab — Kategori x Tipe Penulis (Heatmap %)




Penjelasan: Cross tab (dinormalisasi per baris) menunjukkan proporsi tipe penulis di setiap kategori, memperjelas pola dari grouped bar chart sebelumnya dalam skala persentase untuk 8 kategori teratas.

Insight 1: ENTERTAINMENT memiliki proporsi Single Author tertinggi (75,6%), diikuti POLITICS (64%) — kedua kategori ini paling condong ke gaya penulisan individual/opini.

Insight 2: HEALTHY LIVING punya proporsi Unknown Author terendah (5,4%), menunjukkan pencatatan penulis paling rapi di kategori ini, berbanding terbalik dengan WELLNESS yang proporsi Unknown-nya cukup tinggi (27,8%).


5. Boxplot — Jumlah Kata Headline per Kategori (Top 8)



Penjelasan: Boxplot membandingkan sebaran `Headline_Word_Count` di 8 kategori teratas, diurutkan dari median terendah ke tertinggi.

Insight 1: *ENTERTAINMENT* memiliki median headline terpanjang (11 kata) dan sebaran paling sempit, sedangkan *WELLNESS* & *TRAVEL* memiliki median terpendek (8 kata) — menunjukkan gaya judul yang berbeda antar kategori: berita hiburan cenderung lebih deskriptif/panjang, sementara travel/wellness lebih ringkas.

6. Correlation Heatmap — Variabel Numerik



Penjelasan: Correlation heatmap menampilkan koefisien korelasi Pearson antar seluruh variabel numerik dalam dataset (Year, Month, Headline_Word_Count, Num_Authors, Short_Description_Word_Count).

Insight 1: Korelasi tertinggi (di luar diagonal) adalah antara Num_Authors dan Short_Description_Word_Count ($r = 0,48$, positif sedang) — artikel dengan lebih banyak penulis cenderung memiliki deskripsi yang lebih panjang, masuk akal karena artikel kolaboratif umumnya lebih mendalam/panjang secara konten.

Kesimpulan Umum

- Secara umum, korelasi antar variabel numerik dalam dataset ini tergolong lemah hingga sedang — tidak ada hubungan linear yang sangat kuat, wajar mengingat sebagian besar variabel bersifat deskriptif/kategorikal, bukan hasil pengukuran kuantitatif langsung.
- Pola penulisan (jumlah penulis, gaya judul) berbeda signifikan antar kategori berita — ini bisa menjadi fitur pembeda (predictor) yang berguna jika dataset dipakai untuk klasifikasi kategori.
- Ditemukan indikasi kuat perubahan taksonomi kategori dari waktu ke waktu (WELLNESS → HEALTHY LIVING, PARENTING → PARENTS) — analisis tren jangka panjang berbasis nama kategori perlu mempertimbangkan penggabungan kategori yang secara substansi sama.
- Placeholder hasil data cleaning (Short_Description kosong diisi teks default) menciptakan pola artifisial pada scatter plot — perlu dikecualikan/ditandai terpisah pada analisis kuantitatif teks lebih lanjut.