

Ringkasan Hasil

Analisis Korelasi Data — News Category Dataset

Materi Hari Kamis — Korelasi Data | Dataset: final_clean_dataset.csv (209.480 baris)

Tanggal: 6 Agustus 2026

Dokumen pendamping: Correlation_Matrix.xlsx (tabel lengkap) dan Heatmap.png (visualisasi)

1. Interpretasi Korelasi

1.1 Pasangan dengan korelasi bermakna ($|r| > 0.2$)


Pasangan Variabel	r	Kekuatan & Arah	Interpretasi
Num_Authors ↔ Short_Desc_Word_Count	0.48	Sedang, positif	Artikel dengan lebih banyak penulis cenderung punya deskripsi lebih panjang
Year ↔ Short_Desc_Word_Count	-0.31	Lemah-sedang, negatif	Deskripsi artikel cenderung memendek seiring bertambahnya tahun
Headline_Word_Count ↔ Num_Authors	-0.26	Lemah, negatif	Artikel kolaboratif (banyak penulis) cenderung punya judul sedikit lebih pendek
Headline_Word_Count ↔ Short_Desc_Word_Count	-0.23	Lemah, negatif	Judul panjang sedikit berasosiasi dengan deskripsi lebih pendek
Year ↔ Headline_Word_Count	0.22	Lemah, positif	Judul artikel sedikit memanjang seiring bertambahnya tahun

1.2 Pasangan dengan korelasi sangat lemah / diabaikan ($|r| < 0.15$)

Month dan Is_Weekend praktis tidak berkorelasi dengan variabel lain manapun (semua $|r| < 0.11$) — artinya waktu publikasi dalam siklus bulan/minggu tidak memengaruhi panjang judul, deskripsi, atau jumlah penulis artikel.

2. Analisis: Variabel Paling Berpengaruh, Independen, dan Dependen

2.1 Variabel Paling Berpengaruh



Diukur dari rata-rata nilai absolut korelasi terhadap seluruh variabel lain, Short_Description_Word_Count adalah variabel paling berpengaruh dalam dataset ini (rata-rata $|r| = 0,211$), diikuti Num_Authors (0,177). Variabel ini paling banyak 'terhubung' dengan variabel lain, menjadikannya kandidat kuat sebagai variabel target/output jika dataset dipakai untuk pemodelan prediktif terkait konten artikel.


2.2 Variabel Independen (Predictor)

- Year & Month — bersifat given/eksogen, ditentukan oleh waktu publikasi dan tidak dipengaruhi oleh isi artikel. Cocok sebagai variabel independen dalam analisis tren.
- Is_Weekend — turunan langsung dari tanggal publikasi, juga bersifat independen/eksogen terhadap konten artikel.
- Num_Authors — dapat dianggap independen secara editorial (keputusan redaksi berapa penulis dilibatkan) meski pada praktiknya berkorelasi dengan variabel lain.

2.3 Variabel Dependen (Outcome)

- Short_Description_Word_Count — paling masuk akal sebagai variabel dependen karena panjangnya paling banyak dipengaruhi kombinasi Num_Authors, Year, dan Headline_Word_Count (rata-rata $|r|$ tertinggi).
- Headline_Word_Count — turut berperan sebagai outcome yang dependen terhadap Year (tren memanjang) dan Num_Authors.

3. Visualisasi Pendukung: Pasangan Korelasi Terkuat



Scatter plot Num_Authors vs Short_Description_Word_Count ($r = 0,48$) — pasangan dengan korelasi terkuat di dataset ini — menegaskan pola: semakin banyak penulis yang terlibat, semakin panjang pula deskripsi singkat yang dihasilkan, meskipun sebarannya masih cukup lebar (bukan hubungan deterministik).

4. Ringkasan Hasil

- Tidak ditemukan korelasi kuat ($|r| > 0,5$) antar variabel numerik manapun dalam dataset ini — wajar mengingat sebagian besar variabel bersifat deskriptif/editorial, bukan hasil pengukuran fisik yang saling bergantung erat.
- Korelasi terkuat: Num_Authors ↔ Short_Description_Word_Count ($r = 0,48$, sedang-positif).
- Short_Description_Word_Count adalah variabel paling berpengaruh/terhubung, sehingga paling cocok diposisikan sebagai variabel dependen pada analisis atau pemodelan lanjutan.
- Year & Month/Is_Weekend paling tepat diposisikan sebagai variabel independen karena sifatnya eksogen (given oleh waktu, bukan hasil konten artikel).
- Ditemukan tren menarik: seiring waktu (Year naik), judul artikel (Headline_Word_Count) cenderung memanjang ($r = 0,22$) sementara deskripsi singkat (Short_Description_Word_Count) cenderung memendek ($r = -0,31$) — kemungkinan mencerminkan perubahan gaya editorial HuffPost dari tahun ke tahun.