

Univariate Report

Analisis Univariate — News Category Dataset

Materi Hari Selasa — Analisis Univariate | Dataset: `final_clean_dataset.csv` (209.480 baris)


Tanggal: 4 Agustus 2026

Ringkasan Dataset

Dataset yang dianalisis merupakan hasil tahap Data Preparation sebelumnya, berisi 209.480 artikel berita dari 42 kategori, dengan rentang tanggal publikasi 2012–2022. Laporan ini berfokus pada analisis univariate — mengeksplorasi distribusi tiap variabel secara individual menggunakan histogram, bar chart, pie chart, dan boxplot.

Visualisasi & Interpretasi

1. Histogram — Distribusi Jumlah Kata pada Headline



Penjelasan: Histogram menunjukkan sebaran jumlah kata (`Headline_Word_Count`) pada judul artikel. Sebagian besar judul berisi antara 7-12 kata, dengan puncak (mode visual) di sekitar 10-11 kata. Rata-rata (mean = 9,6) dan median (10,0) berada sangat berdekatan, menandakan distribusi yang mendekati simetris.

Insight: Panjang judul cukup konsisten di seluruh dataset ($std \approx 3,1$ kata), mengindikasikan gaya penulisan headline yang relatif seragam di HuffPost. Skewness sangat kecil (0,07) mengonfirmasi distribusi mendekati normal, hanya sedikit condong ke kanan karena beberapa judul yang sangat panjang.

2. Bar Chart — Top 10 Kategori Berita Terbanyak




Penjelasan: Bar chart menampilkan 10 dari 42 kategori dengan jumlah artikel terbanyak. POLITICS jauh mendominasi dengan 35.587 artikel, lebih dari dua kali lipat kategori kedua (WELLNESS, 17.941 artikel).

Insight: 10 kategori teratas ini menyumbang hampir 60% (59,6%) dari keseluruhan dataset, artinya distribusi kategori sangat tidak merata (*imbalanced*). Ini penting diperhatikan jika dataset akan dipakai untuk pemodelan klasifikasi — kategori minoritas berisiko kurang terwakili.

3. Pie Chart — Distribusi Jumlah Penulis per Artikel (Author_Type)


Distribusi Jumlah Penulis per Artikel (Author_Type)



Penjelasan: Pie chart (donut) menunjukkan proporsi artikel berdasarkan jumlah penulisnya: Single (1 penulis) 42,9%, Multiple (>1 penulis) 39,2%, dan Unknown (penulis tidak tercatat) 17,8%.

Insight: *Proporsi artikel dengan penulis tunggal dan kolaboratif hampir seimbang, menunjukkan budaya penulisan kolaboratif cukup umum di HuffPost. Porsi 'Unknown' yang cukup besar (hampir 1 dari 5 artikel) adalah catatan kualitas data yang perlu diperhatikan pada analisis lanjutan yang melibatkan atribusi penulis.*


4. Boxplot — Jumlah Kata pada Headline (Deteksi Outlier)



Penjelasan: Boxplot memperlihatkan sebaran `Headline_Word_Count` beserta outlier-nya. Rentang IQR (Q1-Q3) berada di 8-12 kata, dengan batas wajar (whisker) 2-18 kata. Titik-titik oranye di luar batas adalah outlier — judul yang jauh lebih panjang dari kebanyakan.

Insight: Ditemukan 942 artikel (0,45%) dengan judul di luar rentang wajar, ada yang mencapai 44 kata. Jumlahnya sangat kecil secara proporsi sehingga tidak perlu dihapus, namun bisa ditandai/diperiksa terpisah karena kemungkinan merupakan judul gabungan/listicle (mis. 'X Cara... ' yang panjang).


5. Bar Chart — Jumlah Artikel per Tahun (2012–2022)



Penjelasan: Bar chart menunjukkan tren jumlah artikel per tahun. Jumlah artikel relatif stabil di kisaran 30.000-34.000 dari 2012-2017, lalu turun drastis mulai 2018 (9.734 artikel) dan terus menurun hingga hanya 1.398 artikel di 2022.

Insight: Penurunan tajam sejak 2018 (ditandai warna oranye) kemungkinan besar bukan tren editorial murni, melainkan indikasi perubahan pada proses pengumpulan/scraping data sumber dataset ini. Analisis time-series pada data 2018 ke atas perlu dilakukan dengan hati-hati karena volumenya jauh lebih kecil dan tidak proporsional.

6. Boxplot — Jumlah Penulis per Artikel (Num_Authors)



Penjelasan: Boxplot Num_Authors menunjukkan median 1 penulis, dengan IQR 1-2 penulis. Whisker atas mentok di 3 penulis, sedangkan artikel dengan 4-10 penulis tercatat sebagai outlier (titik oranye).

Insight: Sebanyak 16.865 artikel (8,05%) memiliki jumlah penulis di luar rentang wajar (lebih dari 3 penulis) — jauh lebih banyak dibanding outlier pada Headline_Word_Count. Ini wajar mengingat beberapa artikel berasal dari kantor berita (mis. Associated Press/AP) yang sering mencantumkan banyak kontributor sekaligus.

Kesimpulan Umum

- Distribusi Headline_Word_Count mendekati normal dan konsisten — mengindikasikan gaya penulisan judul yang cukup beragam.
- Distribusi Category sangat tidak merata; POLITICS mendominasi dan 10 kategori teratas mencakup ~60% data — perlu strategi khusus (mis. resampling) jika dipakai untuk model klasifikasi.
- Jumlah penulis (Num_Authors) didominasi 1-2 penulis, dengan sebagian kecil artikel kolaboratif besar dari kantor berita.
- Volume data menurun drastis sejak 2018 — perlu dikonfirmasi ke pemilik data apakah ini karena keterbatasan cakupan pengumpulan data, sebelum dipakai untuk analisis tren jangka panjang.
- Outlier pada Headline_Word_Count (0,45%) dan Num_Authors (8,05%) relatif kecil dan masih masuk akal secara konteks berita — tidak direkomendasikan untuk dihapus, cukup ditandai untuk analisis lanjutan.