

Outlier & Pattern Analysis

Analisis Outlier, Distribusi & Pola Data — Retail Sales Dataset


Materi Hari Rabu — Outlier & Pattern Analysis | Dataset: retail_sales_dataset.csv (1.000 transaksi)

Tanggal: 12 Agustus 2026

1. Ringkasan Temuan

Analisis outlier standar (metode IQR) pada kolom Quantity, Price per Unit, Total Amount, dan Age menghasilkan 0 outlier di keseluruhan dataset. Namun, penggalan lebih dalam mengungkap dua temuan penting: (1) outlier statistik justru muncul ketika data disegmentasi per kategori produk, dan (2) pola bisnis anomali — tidak ada satupun pelanggan yang bertransaksi lebih dari sekali.


2. Distribusi Data



Distribusi Total Amount bersifat multimodal — hanya ada 18 nilai total transaksi yang mungkin (bukan kontinu), karena Price per Unit dibatasi pada 5 tingkatan harga tetap (Rp25, 30, 50, 300, 500) dan Quantity hanya 1-4. Kombinasi keduanya menghasilkan sejumlah nilai Total Amount yang diskret, bukan distribusi normal/kontinu seperti pada data transaksi ritel riil pada umumnya.


Implikasi: karena data bersifat diskret dan dibatasi (bounded), metode deteksi outlier berbasis IQR standar tidak dapat mendeteksi anomali di level dataset keseluruhan — semua nilai memang 'valid' dan berada dalam rentang yang telah ditentukan (kemungkinan dataset ini adalah data sintetis untuk latihan, bukan hasil scraping transaksi nyata).

3. Boxplot — Deteksi Outlier per Kategori



Ketika Total Amount dianalisis per kategori (bukan digabung), pola berbeda muncul: kategori Clothing memiliki IQR (Q1-Q3) yang lebih sempit (Rp60 - Rp600) dibanding Beauty dan Electronics (Rp60/75 - Rp900). Akibatnya, batas atas wajar (upper bound) untuk Clothing hanya Rp1.410, sehingga transaksi senilai Rp1.500 dan Rp2.000 pada kategori ini terdeteksi sebagai outlier statistik — meski nilai yang sama dianggap normal di Beauty/Electronics.

Kategori	Q1	Q3	Upper Bound	Jumlah Outlier
Beauty	Rp 75	Rp 900	Rp 2.137	0
Clothing	Rp 60	Rp 600	Rp 1.410	32 (9,1%)
Electronics	Rp 60	Rp 900	Rp 2.160	0



Boxplot Price per Unit menegaskan bahwa harga terbagi jadi 5 tingkatan diskret yang identik di ketiga kategori — bukan variabel kontinu, sehingga boxplot per kategori terlihat sangat mirip satu sama lain.


4. Identifikasi Outlier

Outlier: 32 transaksi (9,1% dari transaksi Clothing) dengan Total Amount Rp1.500 atau Rp2.000, yang secara statistik outlier khusus dalam konteks kategori Clothing.


Penyebab: Seluruh 32 outlier ini adalah kombinasi pembelian dalam jumlah besar (Quantity 3-4) pada tingkat harga tertinggi (Price per Unit = Rp500) — yaitu pembelian pakaian premium dalam jumlah banyak sekaligus. Tidak ada perbedaan signifikan pada usia (rata-rata 40,7 tahun vs 42,1 tahun) maupun gender (17 Female, 15 Male) antara transaksi outlier dan normal — jadi penyebabnya murni kombinasi quantity x price, bukan karakteristik demografis tertentu.

Dampak terhadap Bisnis: Transaksi ini BUKAN kesalahan data atau anomali yang perlu 'dibersihkan' — melainkan sinyal segmen pelanggan bernilai tinggi (bulk buyer kategori Clothing) yang berpotensi untuk program loyalitas atau penawaran bundling khusus. Menghapus baris ini sebagai 'outlier' dalam analisis rutin akan menghilangkan visibilitas terhadap 9,1% transaksi Clothing yang justru paling menguntungkan per transaksinya.

5. Pola Data (Scatter Plot)



Scatter plot Quantity vs Price per Unit menunjukkan pola grid yang jelas (4 kolom x 5 baris) — mengonfirmasi bahwa kedua variabel bersifat diskret/kategorikal dalam praktiknya, bukan variabel kontinu bebas. Tidak ada korelasi visual antara Quantity dan Price per Unit (keduanya independen, $r=0,02$).



Scatter plot Usia vs Total Amount menunjukkan sebaran titik horizontal merata di semua kelompok usia (18-64 tahun) — tidak ada pola/tren yang mengindikasikan kelompok usia tertentu berbelanja lebih banyak. Pola ini konsisten dengan temuan segmentasi usia sebelumnya bahwa revenue terdistribusi relatif merata di usia produktif.

6. Pola Bisnis Kritis: Tidak Ada Pelanggan Berulang

Temuan pola paling signifikan bukan berasal dari boxplot/scatter, melainkan dari pemeriksaan Customer ID: dari 1.000 transaksi, seluruhnya berasal dari 1.000 Customer ID yang berbeda — tidak ada satupun pelanggan yang bertransaksi lebih dari 1 kali.

Penyebab: Kemungkinan besar dataset ini disusun secara sintesis (untuk keperluan latihan/edukasi) dengan Customer ID di-generate unik per baris, bukan hasil pencatatan transaksi bisnis riil yang biasanya menunjukkan pelanggan berulang.

Dampak terhadap Bisnis: Jika pola ini terjadi pada data transaksi nyata, ini adalah red flag serius — retensi pelanggan 0% berarti seluruh revenue bergantung pada akuisisi pelanggan baru terus-menerus (biaya lebih mahal dibanding mempertahankan pelanggan lama). Analisis Customer Lifetime Value (CLV) dan strategi retensi tidak dapat dilakukan pada dataset ini karena tidak ada histori transaksi berulang untuk dianalisis.

7. Kesimpulan

- Tidak ditemukan outlier pada level dataset keseluruhan (metode IQR standar) karena data bersifat diskret/bounded — bukan berarti data 'sempurna', melainkan karakteristik desain dataset (kemungkinan sintesis).
- Segmentasi per kategori mengungkap 32 outlier tersembunyi (9,1% transaksi Clothing) yang justru merupakan sinyal bisnis positif (bulk buyer), bukan kesalahan data.
- Distribusi Total Amount multimodal akibat struktur harga bertingkat (5 tier) — bukan hasil proses bisnis kontinu.
- Pola paling kritis dari sisi bisnis: 0% customer retention — setiap transaksi berasal dari pelanggan unik berbeda, yang jika nyata akan sangat berdampak pada strategi akuisisi vs retensi pelanggan.
- Rekomendasi: sebelum menerapkan aturan penghapusan outlier secara otomatis, selalu analisis per-segmen (kategori, pelanggan) terlebih dahulu — outlier di level agregat bisa jadi pola normal yang justru penting di level segmen.